

# Estudo comparativo de métodos de segmentação das bordas de lesões em imagens dermatoscópicas

Pedro Vinícius Macêdo de Araújo, Geraldo Braz Junior

Curso de Ciência da Computação – Universidade Federal do Maranhão (UFMA) –  
Campus do Bacanga  
(98) 3272 8000 – São Luís – MA– Brasil

pedro.vma96@gmail.com, geraldo.braz@ufma.br

**Abstract.** *Precise border detection is often the first step in dermoscopy lesion analysis, as various clinically interesting features like lesion symmetry and extraction of clinical features depends of a precise border detection. In this paper, the performance of various thresholding algorithms will be evaluated in a task of dermoscopy lesion segmentation.*

**Resumo.** *A detecção precisa de bordas é o primeiro passo para a análise de lesões dermatoscópicas, já que várias características de interesse clínico como simetria da lesão e extração de atributos clínicos dependem criticamente de uma detecção precisa da borda. Neste trabalho será analisado o desempenho de vários algoritmos de limiarização na tarefa de segmentar lesões dermatoscópicas.*

## 1. Introdução

Dermatoscopia é uma técnica para avaliar lesões pigmentadas e não pigmentadas, tornando estruturas abaixo da superfície da pele mais facilmente visíveis quando comparadas com imagens clínicas tradicionais [Celebi et al., 2009]. A dermatoscopia permite a identificação de várias características morfológicas de interesse clínico, como glóbulos, manchas e redes de pigmentos. Apesar disso, foi demonstrado que a dermatoscopia pode diminuir a precisão do diagnóstico nas mãos de dermatologistas inexperientes. Assim, para diminuir esses erros, é necessário o desenvolvimento de técnicas de análise computadorizadas que possam auxiliar no processo de detecção e diagnóstico.

Detecção automática de bordas é geralmente o primeiro passo na análise automática ou semiautomática de imagens dermatoscópicas, pois uma detecção precisa das bordas é crucial para uma avaliação adequada pelo especialista. A detecção automática é uma tarefa que apresenta problemas por causa de diversos fatores: baixo contraste entre a lesão e a pele em volta, bordas irregulares e embaçadas, artefatos na imagem como extremidades pretas, cabelo sobre a lesão e vasos sanguíneos, coloração variada dentro da lesão etc. Uma das técnicas para destacar as bordas de uma lesão é a limiarização.

A limiarização de imagens consiste na extração de um objeto do plano de fundo de uma imagem e é uma das aplicações mais comuns em análise de imagens. Entre os métodos de limiarização, a limiarização em dois níveis separa os pixels de uma imagem em duas regiões (o objeto e o fundo); uma região contém os pixels com valores de cinza menores que o limiar (*threshold*) e a outra contém pixels com valores de cinza acima do *threshold*. Geralmente, o *threshold* é encontrado no vale mais profundo do histograma,

porém quando o valor não é evidente, é muito difícil encontrar um valor de *threshold* apropriado.

## 2. Metodologia

O objetivo deste trabalho é avaliar o desempenho de vários algoritmos de limiarização e segmentação na tarefa de destacar as bordas das lesões de um conjunto de imagens dermatoscópicas. A Figura 1 apresenta as etapas do desenvolvimento deste estudo.



Figura 1. Diagrama da metodologia do estudo.

As subseções seguintes apresentam com maior detalhe cada etapa da metodologia.

### 2.1. Banco de imagens e bibliotecas utilizadas

Os testes neste trabalho foram executados no banco de imagens ISIC 2016 ["ISIC Project | ISDIS", 2017], em uma seleção de 375 imagens de lesões dermatoscópicas. Cada imagem é acompanhada de uma máscara binária composta da lesão previamente destacada por um especialista. Neste trabalho foi utilizado a biblioteca OpenCV 3.0 ["OpenCV 3.0 - OpenCV library", 2017] para a implementação dos algoritmos. O OpenCV (*Open Source Computer Vision Library*) é uma biblioteca de código aberto para o desenvolvimento de aplicativos na área de visão computacional, composta de diversos módulos e algoritmos pré-implementados de processamento de imagens e visão computacional.

### 2.2. Pré-processamento

Cada imagem teve seu canal azul separado, pois as lesões geralmente se destacam mais neste canal [Celebi et al., 2009]. Também foram feitos dois testes, um utilizando o algoritmo de *gaussian blur* com o objetivo de suavizar os contornos da imagem e outro sem nenhum algoritmo. A Figura 2 mostra um exemplo de imagem dermatoscópica com e sem o filtro *gaussian blur*.




Figura 2. Lesão dermatoscópica à esquerda e a mesma lesão com filtro *gaussian blur* à direita.

### 2.3. Métodos de detecção de borda

Os 6 algoritmos abaixo foram aplicados em todas as 375 imagens, com e sem o filtro gaussiano.

### 2.3.1. Image thresholding by minimizing the measures of fuzziness

Este algoritmo utiliza o conceito de conjunto *fuzzy* para obter um valor de *threshold*. Dado um certo valor de *threshold*, a função de pertinência de um pixel (função que determina se o pixel pertence ao objeto a ser destacado ou ao plano de fundo) é definida como a diferença absoluta entre o seu valor de cinza e o valor médios das áreas ao redor (isto é, o objeto ou o plano de fundo). Depois de calculadas as funções de pertinência, uma medida *fuzzy* pode ser minimizada para obter um valor de *threshold* ótimo [Huang; Wang, 1995].

### 2.3.2. Minimum error thresholding

Este algoritmo considera a limiarização como um problema de classificação. Ou seja, se a distribuição dos níveis de cinza do objeto e do plano de fundo são conhecidas, então o *threshold* de erro mínimo pode ser obtido utilizando métodos de decisão estatística. A ideia do algoritmo é otimizar a função de custo relacionada com a taxa média de erro de classificação do pixel [Kittler; Illingworth, 1986].

### 2.3.3. A new method for gray-level picture thresholding using the entropy of the histogram

O algoritmo opera calculando a entropia do histograma. Calculando a entropia, maximiza-se o valor e é obtido uma quantidade igual de pixels brancos e pretos. Com isso é possível obter uma função de avaliação, que pode ser maximizada para o obter o valor ótimo de *threshold* [Kapur; Sahoo; Wong, 1985].

### 2.3.4. Otsu

O algoritmo assume que a imagem contém duas classes de pixels: pixels do plano de fundo e do primeiro plano. A partir do histograma, o algoritmo calcula o *threshold* separando as duas classes de pixels para que sua variância intra-classe seja mínima ou sua variância inter-classe seja máxima. O algoritmo envolve iterar sobre todos os valores de *threshold* possíveis e calcular a medida de variância intra-classe para os pixels de ambos os lados do *threshold* (pixels no plano de fundo ou no primeiro plano). O objetivo é encontrar um *threshold* que tenha uma soma de variância intra-classe mínima [“OTSU thresholding”, 2017].

### 2.3.5. K-Means

O K-Means é um algoritmo de *clustering* que tem como objetivo juntar grupos de dados em grupos menores (chamados de *clusters*) baseado nas suas distâncias entre si. Em processamento de imagens, esse algoritmo pode ser usado para segmentar a imagem, dividindo-a em dois ou mais grupos. O algoritmo funciona encontrando o centroide de cada grupo, sendo cada pixel da imagem associado ao seu centroide mais próximo. O algoritmo continua calculando as novas posições dos centroides e reorganizando os pixels até a diferença entre a posição dos centroides da última e da iteração atual estar abaixo de um limite [Tatiraju; Mehta, 2015].

### 2.3.6. Mean shift

O algoritmo Mean Shift é um algoritmo de *clustering* que pode ser usado para segmentar imagens. O Mean Shift opera definindo uma janela ao redor de cada grupo da imagem e calculando seus respectivos centroides. Depois o algoritmo muda o centro das janelas para cada centroide e repete esse procedimento até convergir, segmentando a

imagem em vários grupos. O algoritmo Mean Shift não necessita de uma definição inicial de quantidade de *clusters* [“Mean Shift Segmentation”, 2017].

## 2.4. Avaliação dos resultados

Após a execução dos algoritmos, o desempenho destes foi avaliado usando o coeficiente de Dice, um método para avaliar a similaridade de duas amostras [Dice, 1945]. A imagem segmentada, resultado dos algoritmos, foi comparada com as máscaras fornecidas pelo banco de imagens, resultando num valor do coeficiente de Dice entre 0 (totalmente diferente) e 1 (totalmente igual). O coeficiente é dado pela seguinte fórmula, onde  $A$  e  $B$  são as duas amostras:

$$Dice(A, B) = \frac{2|A \cap B|}{|A| + |B|}$$

## 3. Resultados

As tabelas 1 e 2 mostram o coeficiente de Dice médio e o desvio padrão de cada algoritmo sem e com gaussiana depois de ser aplicado nas 375 imagens da base de dados. As tabelas também apresentam a quantidade de imagens que obtiveram coeficiente de Dice maior ou menor que um determinado limiar.

**Tabela 1. Resultados sem gaussiana**

Algoritmo	Média	Desvio padrão	Quantidade de imagens com coeficiente de Dice maior ou igual a 0.5	Quantidade de imagens com coeficiente de Dice menor que 0.5	Quantidade de imagens com coeficiente de Dice maior ou igual a 0.9	Quantidade de imagens com coeficiente de Dice menor que 0.9
Huang & Wang	0.611481	0.372383	267	108	95	280
Kittler & Illingworth	0.483177	0.419018	206	169	81	294
Kapur <i>et al.</i>	0.633653	0.340096	274	101	97	278
Otsu	0.668652	0.316972	297	78	89	286
K-Means	0.662016	0.274689	280	95	80	295
Mean Shift	0.674688	0.275338	284	91	84	291

**Tabela 2. Resultados com gaussiana**

Algoritmo	Média	Desvio padrão	Quantidade de imagens com coeficiente de Dice maior ou igual a 0.5	Quantidade de imagens com coeficiente de Dice menor que 0.5	Quantidade de imagens com coeficiente de Dice maior ou igual a 0.9	Quantidade de imagens com coeficiente de Dice menor que 0.9

Huang & Wang	0.633376	0.372646	274	101	118	257
Kittler & Illingworth	0.487462	0.42058	209	166	85	290
Kapur <i>et al.</i>	0.67495	0.312002	290	85	110	265
Otsu	0.689155	0.314666	302	73	100	275
K-Means	0.667396	0.275819	282	93	83	292
Mean Shift	0.676057	0.27583	286	89	87	288

Analisando os resultados, observa-se que o uso do filtro gaussiano provoca uma melhora na média de todos os algoritmos, indicando que esse filtro pode ser utilizado para refinar a acurácia dos algoritmos de segmentação. O algoritmo Mean Shift alcançou a maior média do coeficiente de Dice entre todos os algoritmos. O desvio padrão relativamente alto é explicado pela grande variedade de imagens com diversos artefatos que podem interferir na precisão dos algoritmos.

Apresentamos na Figura 3 um exemplo de imagem com alto coeficiente de Dice (média 0.94857167 entre todos os algoritmos). Nessa imagem o alto contraste entre a lesão e a pele ao redor e a ausência de artefatos e cantos pretos garantiu um bom desempenho da segmentação em todos os algoritmos.



**Figura 3. Lesão dermatoscópica à esquerda, imagem com a lesão destacada pela máscara fornecida pelo banco de imagens no centro e segmentação obtida pelo algoritmo Huang & Wang com gaussiana com coeficiente de Dice 0.955609 à direita.**

Apresentamos na Figura 4 um exemplo de imagem com baixo coeficiente de Dice (média 0.2575108 entre todos os algoritmos). Nessa imagem observa-se a presença de muitos artefatos obstruindo a lesão, além da própria lesão não ter contornos bem definidos.



**Figura 4. Lesão dermatoscópica à esquerda, imagem com a lesão destacada pela máscara fornecida pelo banco de imagens no centro e segmentação obtida pelo algoritmo Huang & Wang com gaussiana com coeficiente de Dice 0.2575108 à direita.**

**pelo algoritmo K-Means com gaussiana com coeficiente de Dice 0.536441 à direita.**

#### **4. Conclusões**

Neste artigo foi feita uma análise do desempenho de vários algoritmos de limiarização na tarefa de segmentar um conjunto de imagens. Observou-se que dentre os algoritmos estudados, o algoritmo Mean Shift alcançou o desempenho mais satisfatório e o uso do filtro gaussiano no pré-processamento das imagens acarreta uma melhora na precisão da segmentação.

Ainda assim, o resultado geral precisa ser melhorado, devido à grande variedade de imagens com bordas pretas, artefatos interferindo na segmentação ou com lesões de pouco contraste com a pele. Isso sugere que a segmentação isolada não é um método adequado para destacar as bordas de lesões em imagens dermatoscópicas. Desse modo, em trabalhos futuros os algoritmos podem ser combinados com outras ferramentas que minimizem o efeito dos fatores prejudiciais à segmentação, ocasionando assim um desempenho mais satisfatório.

#### **Referências**

Celebi, M. et al. Lesion border detection in dermoscopy images. Computerized Medical Imaging and Graphics, 2009.

Dice, L. Measures of the Amount of Ecologic Association Between Species. Ecology, v. 26, n. 3, p. 297-302, 1945.

Huang, L.; Wang, M. Image thresholding by minimizing the measures of fuzziness. Pattern Recognition, 1995.

ISIC Project | ISDIS. Disponível em: <<http://isdis.net/isic-project/>>. Acesso em: 28 maio. 2017.

Kapur, J.; Sahoo, P.; Wong, A. A new method for gray-level picture thresholding using the entropy of the histogram. Computer Vision, Graphics, and Image Processing, 1985.

Kittler, J.; Illingworth, J. Minimum error thresholding. Pattern Recognition, v. 19, 1986.

Mean Shift Segmentation. Disponível em: <[https://www.inf.tu-dresden.de/content/institutes/ki/is/VORTRAG/Vortrag\\_Huong\\_Nguyen.pdf](https://www.inf.tu-dresden.de/content/institutes/ki/is/VORTRAG/Vortrag_Huong_Nguyen.pdf)>. Acesso em: 28 maio. 2017.

OpenCV 3.0 - OpenCV library. Disponível em: <<http://opencv.org/opencv-3-0.html>>. Acesso em: 28 maio. 2017.

OTSU thresholding. Disponível em: <<http://computervisionwithvaibhav.blogspot.com.br/2015/10/otsu-thresholding.html>>. Acesso em: 28 maio. 2017.

Tatiraju, S.; Mehta, A. Image Segmentation using k-means clustering, EM and Normalized Cuts. 2015.